



Università degli Studi di Milano Bicocca

Dipartimento di Informatica, Sistemistica e Comunicazione

Corso di Laurea Magistrale in Informatica

Sintesi Tesi

Relatore: Prof.ssa Elisabetta Fersini

Co-relatore: PhD Giulia Rizzi

Tesi di Laurea Magistrale di:

Davide Pizzo

Matricola 869254

Anno Accademico 2025-2026

I modelli vision-language sono sistemi capaci di elaborare insieme immagini e testo, e negli ultimi anni hanno raggiunto prestazioni notevoli in compiti di comprensione e classificazione di contenuti. La loro architettura è complessa e stratificata: l'informazione visiva attraversa molti strati di elaborazione, all'interno di ognuno dei quali operano in parallelo molte unità indipendenti, e il risultato che si osserva è la sintesi di tutto questo processo. Di ciò che accade all'interno sappiamo poco.

Questa tesi propone di studiare questi modelli in profondità: non limitandosi al loro comportamento generale, ma esaminando come le singole componenti interne si attivino nel corso di un task di classificazione.

L'obiettivo è capire se tutte queste componenti si comportino allo stesso modo, o se alcune presentino caratteristiche distintive che, osservando solo il risultato finale, non si coglierebbero.

Per questa analisi occorre un criterio di valutazione, cioè qualcosa che consenta di dire se il comportamento di una componente sia più o meno interessante di quello di un'altra.

Il criterio adottato in questo studio è il confronto con la percezione umana. Quando una persona osserva un'immagine, lo sguardo non si distribuisce uniformemente, ma si posa su alcune regioni precise, e dove si posa è misurabile. Si può chiedere a un modello la stessa cosa, ovvero a quali regioni della foto dà maggiore salienza.

La domanda su cui fonda la tesi, quindi, è: *in un modello vision-language esistono componenti, nascoste nella sua profondità, la cui attenzione si allinea alla percezione umana meglio di quanto faccia il modello considerato nel suo complesso?*

Il contesto del lavoro svolto è il riconoscimento della misoginia nei meme. I meme sono contenuti dove immagine e testo insieme, creano un significato: un'immagine può essere innocua/offensiva a seconda del testo associato, e viceversa. Sono quindi ottimi per modelli che devono integrare le due modalità, al tempo stesso è un dominio in cui la questione della trasparenza ha ricadute concrete, dato che decisioni automatiche su contenuti di questo tipo incidono su ciò che circola online.

Il lavoro si divide in due direzioni. La prima approfondisce l'analisi di un modello già proposto, nella sua forma più superficiale, in uno studio precedente, approfondendo sempre più le analisi in profondità.

La seconda estende l'analisi a un modello di architettura diversa, verifican-

do se gli strumenti impiegati sono trasferibili e quali adattamenti richiedano.

Per poter interrogare un modello sulle ragioni di una decisione è necessario che prenda una decisione non casualmente. Il compito su cui i modelli sono stati adattati è la classificazione binaria dei meme come misogini o non misogini, tramite addestramento sul dataset MAMI, composto da 10.000 meme in lingua inglese.

L'adattamento è avvenuto secondo due strategie diverse: una più conservativa, dove il modello pre-addestrato resta congelato e viene addestrato soltanto il classificatore posto al di sopra delle rappresentazioni che esso produce, e una più estesa, dove vengono aggiornati anche i parametri del modello di base.

È importante che il classificatore raggiunga prestazioni lontane dalla casualità, perchè spiegare la decisione di un sistema che decida in modo casuale non avrebbe significato.

Una volta addestrati i modelli, per ciascun meme viene prodotta una mappa che indica quali regioni hanno maggiormente contribuito alla decisione. La mappa si compone di due parti. Per la componente visiva si usa Grad-CAM, che individua le zone dell'immagine cui il modello dà maggiore importanza; per la componente testuale si impiegano gli Integrated Gradients, che attribuiscono un peso a ciascuna parola del meme in base a quanto essa spinga il modello verso una determinata decisione. I punteggi testuali vengono poi riportati sulle regioni dell'immagine in cui le parole compaiono fisicamente, individuate mediante OCR, e fusi con la mappa visiva in un'unica rappresentazione.

Quest'ultima è omogenea all'attenzione di un osservatore umano, che non distingue tra il guardare una figura e il leggere una scritta.

Il riferimento umano proviene da un esperimento di eye-tracking condotto in un lavoro di ricerca precedente, che ne ha curato la raccolta, la pulizia e l'organizzazione dei dati. Tramite un apparecchio di eye-tracking è stato registrato dove i partecipanti hanno posato e mantenuto lo sguardo su ciascuno stimolo; da tali registrazioni derivano due artefatti, una mappa di fissazioni e una mappa di salienza. La baseline impiegata in questo lavoro è l'aggregazione delle mappe di tutti i partecipanti per ciascun meme, che attenua le differenze individuali e fa emergere le regolarità collettive. Gli stimoli sono stati 96 meme in lingua italiana.

Il confronto tra le mappe prodotte dai modelli e il riferimento umano non av-

viene soltanto per via qualitativa (osservando le immagini) ma anche numericamente, con due metriche. La NSS valuta la mappa del modello esattamente nei punti in cui si sono verificate le fissazioni umane: valori alti indicano che lo sguardo dei partecipanti si è posato dove il modello attribuisce salienza maggiore, mentre valori vicini a zero indicano un allineamento non superiore al caso. La EMD misura invece la distanza spaziale tra le due distribuzioni tenendo conto dello spazio dell'immagine. Per la NSS si desiderano valori più alti possibile, per la EMD valori più bassi possibile.

I modelli esaminati sono mCLIP, di tipo contrastivo, e mBLIP, di tipo generativo. La differenza tra le due architetture è importante. In mCLIP immagine e testo sono proiettati in uno spazio di rappresentazione condiviso, dove la loro corrispondenza è una grandezza direttamente misurabile; in mBLIP questo spazio non esiste, poiché l'informazione visiva viene trasformata da un modulo di connessione(Q-Former) e immessa nel flusso di elaborazione di un LLM.

La prima fase del lavoro è stata analizzare la pipeline esistente per comprenderne il funzionamento. Compresa questa, si è deciso di approfondire l'analisi in profondità, agganciando l'estrazione delle mappe a livelli diversi dall'ultimo. L'utilizzo dell'ultimo layer è una prassi standard, giustificata dal fatto che ospita le rappresentazioni semanticamente più dettagliate; non è detto tuttavia che sia anche quello la cui attenzione somiglia maggiormente allo sguardo umano. Le analisi condotte confermano questa intuizione: in entrambe le architetture i livelli intermedi risultano migliori secondo entrambe le metriche.

Successivamente l'indagine è scesa a un livello ulteriore di dettaglio, esaminando separatamente le singole head di attenzione di ciascun livello. Si tratta di un cambiamento non soltanto di analisi ma di tecnica: infatti Grad-CAM ricostruisce l'importanza delle regioni a partire dai gradienti della decisione, l'ispezione dell'attention descrive direttamente dove il modello guarda mentre elabora l'immagine, indipendentemente da ciò che avviene a valle.

Dalle matrici risultanti si è individuata, per ciascuna configurazione, la coppia livello-head meglio allineata, e si sono prodotte le heatmap corrispondenti per tutti i 96 stimoli.

L'estensione a mBLIP ha richiesto adattamenti particolari, che costituiscono una parte rilevante del lavoro.

Il primo riguarda la quantità rispetto alla quale calcolare i gradienti per Grad-CAM. In mCLIP questa quantità è la similarità tra immagine e testo,

grandezza nativa del modello contrastivo; in mBLIP non esiste in questa forma e il tentativo di ricostruirla attraverso le proiezioni introdotte dal classificatore ha prodotto mappe degeneri, perchè i gradienti risultavano in larga parte negativi e la mappa collassava. Si è pertanto adottato come segnale il logit prodotto dal classificatore.

Il secondo adattamento riguarda l'estrazione dei pesi di attenzione: il modulo di mBLIP, a differenza di mCLIP, non li rende disponibili, e si è quindi dovuto ricalcolarli manualmente replicando il calcolo interno del modulo(Query,Key,Value,prodotto scalare, applicazione della Softmax...), verificandone la correttezza con il controllo che i pesi di ciascuna unità sommassero all'unità.

L'esplorazione è stata condotta in modo esaustivo su tutte le combinazioni: 168 per mCLIP e 624 per mBLIP, ciascuna valutata su tutti i 96 stimoli e per entrambe le strategie di adattamento.

Sul piano della classificazione, tutte le configurazioni raggiungono prestazioni adeguate. Sul piano dell'allineamento, i risultati mostrano un miglioramento progressivo al crescere della profondità dell'analisi. Nella configurazione di riferimento, con estrazione dal livello terminale, i valori di EMD si collocano tra 12,89 e 15,11. Scendendo al livello ottimale, che in entrambe le architetture si colloca in posizione intermedia, la distanza si riduce fino a 10,80. Isolando la singola unità di attenzione il guadagno è ancora maggiore: l'EMD scende sotto l'8 in tutte e quattro le configurazioni, dimezzandosi rispetto al punto di partenza, mentre la NSS più che raddoppia, passando da valori compresi tra 0,25 e 0,71 a valori prossimi a 1,3.

La risposta alla domanda iniziale è dunque affermativa: all'interno di entrambi i modelli esistono componenti il cui allineamento con la percezione umana è superiore a quello del comportamento umano, e tali componenti si collocano in profondità intermedie della rete anziché nei suoi livelli terminali. Due osservazioni conclusive: la prima è che il modello che classifica meglio non è quello la cui attenzione somiglia maggiormente a quella umana; accuratezza e allineamento sono due cose indipendenti. La seconda è che il divario tra le due architetture, marcato nella configurazione iniziale di riferimento, si riduce di molto in quella ottimale; una parte consistente di ciò che appariva come differenza tra i modelli era in realtà imputabile alla tecnica usata per interrogarli.